



Vilnius universitetas
Matematikos ir informatikos fakultetas
Duomenų mokslo ir skaitmeninių
technologijų institutas

Matematiniai dalykai

prof. dr. Olga Kurasova
Olga.Kurasova@mif.vu.lt

Skaliaras, vektorius, matrica

- **Skaliaras** – skaičius, įprastai priklausantis realiųjų skaičių erdvei, $x \in \mathbb{R}$.
- **Vektorius** – tai skaičių rinkinys, $X \in \mathbb{R}^n$, kurio i -tasis elementas žymimas x_i :

$$X = [x_1, x_2, \dots, x_n].$$

- **Matrica** – tai dvimatis masyvas $A \in \mathbb{R}^{m \times n}$, kurio i -tosios eilutės ir j -tojo stulpelio elementas žymimas a_{ij} :

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}.$$

- Įprastai kintamieji **skaičiai** žymimi pasvirusia mažąja raide (x, y, z, a, \dots); **vektoriai** ir **matricos** žymimi arba didžiąja raide (X, Y, Z, A, \dots), arba pastorinta mažąja ($\mathbf{x}, \mathbf{y}, \mathbf{z}, \mathbf{a}, \dots$)).

Transponuota matrica

- Sukeitus matricos eilutes ir stulpelius, gaunama **transponuota matrica**, kuri žymima A^T :

$$A = \begin{bmatrix} a_{11} & a_{21} & \cdots & a_{m1} \\ a_{12} & a_{22} & \cdots & a_{m2} \\ \vdots & \vdots & \ddots & \vdots \\ a_{1n} & a_{2n} & \cdots & a_{mn} \end{bmatrix}.$$

Tenzoriai

- Vektoriai apibendrina skaliarus, matricos apibendrina vektorius, o **tenzoriai** apibendrina matricas.
- **Tenzoriai** – tai daugiamačiai masyvai (matricos).
- Pavyzdyje pateiktas trijų dimensijų tenzorius:

$$T = \begin{bmatrix} [1 \ 3] & [2 \ 5] & [1 \ 6] \\ [3 \ 5] & [7 \ 8] & [0 \ 3] \end{bmatrix}.$$

- Vektoriai yra **pirmos eilės** tenzoriai, matricos – **antros eilės** tenzoriai.

Skaliarinė sandauga

- Dviejų vektorių $X, Y \in \mathbb{R}^n$ **skaliarinė sandauga** (*dot product*) apskaičiuojama taip:

$$X^T Y = \sum_{i=1}^n x_i y_i,$$

čia

$$X = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}, Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}, X^T = [x_1, x_2, \dots, x_n].$$

Išvestinės


- Tarkime turime **funkciją** $f: \mathbb{R} \rightarrow \mathbb{R}$.
- Jos **išvestinė** apibrėžiama taip:

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}.$$

- Jei tokia riba egzistuoja, t. y. egzistuoja $f'(a)$, sakoma, kad funkcija f yra **diferencijuojama** taške a .
- Jei turime $y = f(x)$, šie reiškiniai yra **ekvivalentiški**:

$$f'(x) = y' = \frac{dy}{dx} = \frac{df}{dx} = \frac{d}{dx} f(x).$$

Išvestinės geometrinė prasmė



Dalinės išvestinės

- Tarkime turime n kintamųjų **funkciją** $y = f(x_1, x_2, \dots, x_n)$.
- y **dalinė išvestinė** nuo x_i užrašoma:

$$\frac{\partial y}{\partial x_i} = \lim_{h \rightarrow 0} \frac{f(x_1, \dots, x_{i-1}, x_i + h, x_{i+1}, \dots, x_n) - f(x_1, \dots, x_i, \dots, x_n)}{h}.$$

- Skaičiuojant $\frac{\partial y}{\partial x_i}$, imama $x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n$ kaip konstantos.

Dalinės išvestinės (pavyzdys)

- Apskaičiuokime funkcijos $y = f(x_1, x_2) = x_1^2 + x_2$ **dalines išvestines**:
 - $\frac{\partial y}{\partial x_1} = 2x_1$ (x_2 laikoma **konstanta**, kurios išvestinė lygi 0);
 - $\frac{\partial y}{\partial x_2} = 1$ (x_1 laikoma **konstanta**, kurios išvestinė lygi 0).

Gradientas

- Tarkime turime n kintamųjų **funkcija** $f: \mathbb{R}^n \rightarrow \mathbb{R}$. Jos įvestis yra n -matis vektorius $X = (x_1, x_2, \dots, x_n)^T$, o išvestis – skaliaras.

- **Gradientą** sudaro dalinės išvestinės:

$$\nabla f(X) = \left[\frac{\partial f(x)}{\partial x_1}, \frac{\partial f(x)}{\partial x_2}, \dots, \frac{\partial f(x)}{\partial x_n} \right]^T.$$

- **Antigradientas** yra priešingos krypties vektorius, $-\nabla f(X)$.

Gradientinis nusileidimas


1. Paimamas **pradinis taškas** x_0 , ($t = 0$).
 2. Skaičiuojamas **naujas taškas**: $x_{t+1} = x_t - \eta \nabla f(x_t)$.
 3. Jei nėra tenkinama algoritmo **sustojimo sąlyga**, atliekamas antras žingsnis.
- Čia η yra parametras, įtakojantis optimizavimo žingsnį, dar vadinamas **mokymo greičiu** (*learning rate*).
 - $-\nabla f(x_t)$ yra antigradientas. Optimizavimo metu „judama“ antigradiento kryptimis, t. y. funkcijos mažėjimo kryptimi.

Gradientinis nusileidimas

$$x_0 = 10, \quad x_{t+1} = x_t - \eta \nabla f(x_t)$$

$\eta = 0,2$

$$f(x) = x^2, \quad \nabla f(x) = f'(x) = 2x$$




**Randomas
minimumas**
atlikus 10
žingsnių

Gradientinis nusileidimas

$$x_0 = 10, \quad x_{t+1} = x_t - \eta \nabla f(x_t)$$

$\eta = 0,05$

$$f(x) = x^2, \quad \nabla f(x) = f'(x) = 2x$$




**Minimumas dar
nepasiektas**
atlikus 10
žingsnių

Gradientinis nusileidimas

$$x_0 = 10, \quad x_{t+1} = x_t - \eta \nabla f(x_t)$$

$\eta = 1,1$

$$f(x) = x^2, \quad \nabla f(x) = f'(x) = 2x$$



**Procesas
diverguoja**

funkcijos
minimumas